

Proposal Project CPE232 : Constitution

Topic : (Twenty Constitutions Analysis) Analyze of 20 Thai Constitutions.

สมาชิกกลุ่ม :	กัณฑ์ธีร์ ดวงมณี	67070501003
	นัธวัฒน์ ปริณสิริคุณาวุฒิ	67070501027
	วิศิษฐ์ สุวรรณเนา	67070501042
	ศุภวิชญ์ มารยาท	67070501045
	พลวิชญ์ วัฒนเหมรัตน์	67070501067

Introduction

ประเทศไทยมีรัฐธรรมนูญรวมทั้งสิ้น 20 ฉบับ นับตั้งแต่ปี พ.ศ. 2475 จนถึงปัจจุบัน ซึ่งถือว่าเยอะมากที่สุดเมื่อเทียบกับประเทศที่ปกครองในระบอบประชาธิปไตย รัฐธรรมนูญแต่ละฉบับสะท้อนบริบทการเมืองที่แตกต่างกัน ไม่ว่าจะเป็นรัฐบาลพลเรือน คณะรัฐประหาร หรือสภาเฉพาะกาล ดังนั้นโครงการนี้มีเป้าหมายในการรวบรวม ดิจิทัลไลซ์ และวิเคราะห์รัฐธรรมนูญทั้ง 20 ฉบับในฐานะคลังข้อความ (Text Corpus) โดยใช้เทคนิค OCR, NLP, และ ML เพื่อตอบคำถามหลักว่า “รัฐธรรมนูญไทยเปลี่ยนแปลงอย่างไรตลอด 9 ทศวรรษ และการเปลี่ยนนี้สะท้อนประวัติศาสตร์การเมืองไทยอย่างไร?” นอกจากนี้ยังนำข้อมูล Structured จาก [Constituteproject.org](https://constituteproject.org) ซึ่งจัดทำดัชนีสิทธิ์ตามรัฐธรรมนูญของแต่ละประเทศ มาใช้เปรียบเทียบการคุ้มครองสิทธิในรัฐธรรมนูญไทยแต่ละฉบับเชิงปริมาณ

Objectives

- สร้างคลังข้อความ (Corpus) ของรัฐธรรมนูญ 20 ฉบับ โดยใช้ OCR, และการดึงข้อมูลจากไฟล์ pdf
- วิเคราะห์โครงสร้าง ได้แก่ จำนวนมาตรา ความยาว การแบ่งหมวด และความถี่ในการแก้ไขเพิ่มเติม
- หาการเปลี่ยนแปลงเชิงหัวข้อและภาษา ระหว่างแต่ละยุคการเมือง
- วัดและเปรียบเทียบสิทธิในรัฐธรรมนูญแต่ละฉบับ จากดัชนีของ constituteproject.org
- วัดความคล้ายคลึงระหว่างรัฐธรรมนูญแต่ละฉบับ
- สร้างโมเดล Machine Learning เพื่อวิเคราะห์โครงสร้าง โดยประยุกต์ใช้ความรู้จากวิชา CPE 232 Data Models ในทุกขั้นตอนที่สอดคล้องกับเนื้อหารายวิชา

Data Source

รัฐธรรมนูญและธรรมนูญการปกครอง ประกอบไปด้วยดังนี้

คำอธิบาย	รัฐธรรมนูญและธรรมนูญการปกครอง ของไทย ที่ประกาศใช้ในราชกิจจานุเบกษา ตั้งแต่ปี 2475 ถึงปัจจุบัน
ประเภทของข้อมูล	ข้อมูลขั้นต้น Primary
จัดทำโดย	สำนักวิชาการ สำนักงานเลขาธิการสภาผู้แทนราษฎร
แหล่งที่มา	ระบบคลังสารสนเทศรัฐสภา
สัญญาอนุญาต	Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License
URL	https://catalog.parliament.go.th/dataset/12_01

หมายเหตุ: สีเหลือง คือ เอกสารที่เป็น PDF แบบรูปภาพ และ
สีเขียว คือ เอกสารที่เป็น PDF แบบข้อความ

ชื่อ	วันที่ประกาศใช้	ชื่อ	วันที่ประกาศใช้
รัฐธรรมนูญแห่งราชอาณาจักรสยาม พ.ศ. 2475	10/12/2475	รัฐธรรมนูญแห่งราชอาณาจักรไทย แก้ไขเพิ่มเติม พ.ศ. 2528	14/8/2528
รัฐธรรมนูญแก้ไขเพิ่มเติมว่าด้วยนามประเทศ พ.ศ. 2482	6/10/2482	รัฐธรรมนูญแห่งราชอาณาจักรไทย แก้ไขเพิ่มเติม (ฉบับที่ 2) พ.ศ. 2532	30/8/2532
รัฐธรรมนูญแก้ไขเพิ่มเติมว่าด้วยบทเฉพาะกาล พ.ศ. 2483	4/10/2483	ธรรมนูญการปกครองราชอาณาจักร พุทธศักราช 2534	1/3/2534
รัถธรรมนูญแก้ไขเพิ่มเติมว่าด้วยการเลือกตั้งสมาชิกสภาผู้แทนวรา สตร พุทธศักราช 2485	3/12/2485	รัฐธรรมนูญแห่งราชอาณาจักรไทย พ.ศ. 2534	9/12/2534
รัฐธรรมนูญแห่งราชอาณาจักรไทย พ.ศ. 2489	10/5/2489	รัฐธรรมนูญแห่งราชอาณาจักรไทย แก้ไขเพิ่มเติม (ฉบับที่ 3) พุทธศักราช 2535	30/6/2535
รัฐธรรมนูญแห่งราชอาณาจักรไทย (ฉบับชั่วคราว) พ.ศ. 2490	9/11/2490	รัฐธรรมนูญแห่งราชอาณาจักรไทย แก้ไขเพิ่มเติม (ฉบับที่ 2) พุทธศักราช 2535	30/6/2535
รัฐธรรมนูญแห่งราชอาณาจักรไทย (ฉบับชั่วคราว) แก้ไขเพิ่มเติม พ.ศ. 2490	9/12/2490	รัฐธรรมนูญแห่งราชอาณาจักรไทย แก้ไขเพิ่มเติม (ฉบับที่ 1) พุทธศักราช 2535	30/6/2535
รัฐธรรมนูญแห่งราชอาณาจักรไทย (ฉบับชั่วคราว) แก้ไขเพิ่มเติม (ฉบับที่ 2) พ.ศ. 2491	3/2/2491	รัฐธรรมนูญแห่งราชอาณาจักรไทย แก้ไขเพิ่มเติม (ฉบับที่ 4) พุทธศักราช 2535	12/9/2535
รัฐธรรมนูญแห่งราชอาณาจักรไทย (ฉบับชั่วคราว) แก้ไขเพิ่มเติม (ฉบับที่ 3) พ.ศ. 2491	24/8/2491	รัฐธรรมนูญแห่งราชอาณาจักรไทย แก้ไขเพิ่มเติม (ฉบับที่ 5) พุทธศักราช 2538	10/2/2538
รัฐธรรมนูญแห่งราชอาณาจักรไทย พ.ศ. 2492	23/3/2492	รัฐธรรมนูญแห่งราชอาณาจักรไทย แก้ไขเพิ่มเติม (ฉบับที่ 6) พุทธศักราช 2539	22/10/2539
รัฐธรรมนูญแห่งราชอาณาจักรไทย พุทธศักราช 2475 แก้ไขเพิ่มเติม พุทธศักราช 2495	8/3/2495	รัฐธรรมนูญแห่งราชอาณาจักรไทย พุทธศักราช 2540	11/10/2540
ธรรมนูญการปกครองราชอาณาจักร [2502]	28/1/2502	รัฐธรรมนูญแห่งราชอาณาจักรไทย แก้ไขเพิ่มเติม (ฉบับที่ 1) พุทธศักราช 2548	11/7/2548
รัฐธรรมนูญแห่งราชอาณาจักรไทย พ.ศ. 2511	20/6/2511	รัฐธรรมนูญแห่งราชอาณาจักรไทย (ฉบับชั่วคราว) พุทธศักราช 2549	1/10/2549
ธรรมนูญการปกครองราชอาณาจักร พุทธศักราช 2515	15/12/2515	รัฐธรรมนูญแห่งราชอาณาจักรไทย (2550)	24/8/2550
รัฐธรรมนูญแห่งราชอาณาจักรไทย พ.ศ. 2517	7/10/2517	รัฐธรรมนูญแห่งราชอาณาจักรไทย แก้ไขเพิ่มเติม (ฉบับที่ 1) พุทธศักราช 2554	4/3/2554
รัฐธรรมนูญแห่งราชอาณาจักรไทย แก้ไขเพิ่มเติม พ.ศ. 2518	23/1/2518	รัฐธรรมนูญแห่งราชอาณาจักรไทย แก้ไขเพิ่มเติม (ฉบับที่ 2) พุทธศักราช 2554	4/3/2554
รัฐธรรมนูญแห่งราชอาณาจักรไทย พ.ศ. 2519	22/10/2519	รัฐธรรมนูญแห่งราชอาณาจักรไทย (ฉบับชั่วคราว) พุทธศักราช 2557	22/7/2557
รัฐธรรมนูญการปกครองราชอาณาจักร พ.ศ. 2520	9/11/2520	รัฐธรรมนูญแห่งราชอาณาจักรไทย (พหุศักราช 2560)	6/4/2560
รัฐธรรมนูญแห่งราชอาณาจักรไทย พุทธศักราช 2521	22/12/2521	รัฐธรรมนูญแห่งราชอาณาจักรไทย แก้ไขเพิ่มเติม (ฉบับที่ 1) พุทธศักราช 2564	21/11/2564

Methodologies

- 1. Data Preparation:** เนื่องจากรัฐธรรมนูญไทยมีรูปแบบที่แตกต่างกันตามยุคสมัย จึงแบ่งวิธีเตรียมชุดข้อมูลออกเป็น 2 แบบ ได้แก่ รัฐธรรมนูญในรูปแบบรูปภาพในช่วง พ.ศ. 2475–2502 ซึ่งดำเนินการผ่าน Optical Character Recognition (OCR) ด้วย **Typhoon OCR 1.5** ที่รองรับภาษาไทยโดยเฉพาะ และดึงข้อความ (text extraction) จากรัฐธรรมนูญในรูปแบบ PDF ในช่วง พ.ศ. 2511–2560 ออกมาโดยทั้งสองแบบจะผ่านการตรวจสอบความถูกต้องของข้อความภายหลัง
- 2. Exploratory Data Analysis (EDA):** การวิเคราะห์ขั้นตอนนี้ช่วยให้สามารถตรวจสอบคุณภาพของข้อมูลจาก OCR และ text extraction รวมถึงช่วยในการออกแบบขั้นตอนการประมวลผลข้อมูลและการสร้างแบบจำลอง Machine Learning
 - a. Dataset Overview:** ทำการสำรวจข้อมูลภาพรวมของชุดข้อมูล เช่น ความยาวของข้อความ จำนวนรัฐธรรมนูญทั้งหมดในชุดข้อมูล ช่วงปีของรัฐธรรมนูญที่ศึกษา จำนวนหมวด (chapters) และมาตรา (articles) ในแต่ละฉบับ
 - b. Text Analysis เช่น** จำนวนคำทั้งหมดในรัฐธรรมนูญแต่ละฉบับ, จำนวนคำเฉลี่ยต่อมาตรา, การกระจายตัวของความยาวข้อความในแต่ละมาตรา, คำที่เกี่ยวข้องหรือ Keywords ต่าง ๆ
- 3. Data Cleaning and Data Preprocessing**
 - a. Normalization** Normalize Unicode ภาษาไทย และลบ Header/Footer ที่ไม่เกี่ยวข้องออก, แบ่งข้อความเป็นหน่วยโครงสร้าง: หมวด / มาตรา / วรรค และ Standardize ฟิลด์ Metadata เช่น วันที่ ตัวเลขมาตรา และป้ายชื่อยุคการเมือง
 - b. Tokenization ภาษาไทย:** โดยใช้เครื่องมือสำหรับการตัดคำภาษาไทย เช่น PyThaiNLP Attacut เพื่อแบ่งข้อความออกเป็นคำ (tokens) ที่สามารถนำไปใช้การวิเคราะห์ต่อไปได้
 - c. Text Cleaning เช่น** ลบคำที่ไม่ให้ข้อมูลเชิงความหมายสำคัญ (Stopword Removal) เช่น คำเชื่อม หรือคำทั่วไปในภาษาไทย, แปลงเลขไทยให้เป็นเลขอารบิกและ ลบสัญลักษณ์ที่ไม่ได้เกี่ยวข้องกับเนื้อหา
- 4. Feature Extraction**
 - a.** เพื่อให้แบบจำลอง Machine Learning และการ Visualization สามารถประมวลผลข้อมูลข้อความได้ จำเป็นต้องแปลงข้อความให้อยู่ในรูปแบบเชิงตัวเลข
 - i. Bag-of-Words (BoW)** เพื่อแสดงความถี่ของคำในเอกสาร
 - ii. TF-IDF (Term Frequency-Inverse Document Frequency)** เพื่อสะท้อนความสำคัญของคำในแต่ละรัฐธรรมนูญ
 - iii. Word Embeddings** เพื่อแทนความหมายของคำในรูปแบบเวกเตอร์ โดยใช้ Language Model ภาษาไทย เช่น WangChanBERTa
- 5. Data Visualization**
 - a.** เน้นกราฟที่สามารถแสดงแนวโน้มและการเปรียบเทียบข้อมูลระหว่างรัฐธรรมนูญแต่ละฉบับ เช่น
 - i. Timeline of Constitutions:** สร้าง timeline แสดงลำดับเวลาของรัฐธรรมนูญไทย เพื่อให้เห็นภาพรวมของการเปลี่ยนแปลงทางการเมืองในแต่ละช่วงเวลา โดยกราฟจะแสดงปีที่รัฐธรรมนูญเริ่มใช้และปีที่สิ้นสุดการใช้งาน
 - ii. Rights Distribution Across Constitutions:** ผลลัพธ์จะแสดงในรูปแบบ heatmap ซึ่งแกนหนึ่งเป็นประเภทของสิทธิ และอีกแกนหนึ่งเป็นปีของรัฐธรรมนูญ
 - iii. Amendment Frequency:** สร้างกราฟแสดง จำนวนครั้งของการแก้ไขรัฐธรรมนูญ (amendments) ในแต่ละฉบับ เพื่อวิเคราะห์ความเสถียรของรัฐธรรมนูญในแต่ละยุค
 - iv. Topic Distribution in Constitutions:** ใช้ผลลัพธ์จากการวิเคราะห์ **topic modeling** เพื่อแสดงหัวข้อสำคัญในรัฐธรรมนูญแต่ละฉบับ
 - v. Constitution Similarity Matrix:** เพื่อวิเคราะห์ความคล้ายคลึงกันของรัฐธรรมนูญแต่ละฉบับ จะมีการคำนวณ **document similarity** จากข้อความของรัฐธรรมนูญ
- 6. Machine Learning Modeling**
 - a. Topic Modeling:** ใช้เทคนิคการเรียนรู้แบบไม่ต้องมีป้ายกำกับ (unsupervised learning) เพื่อค้นหารูปแบบหัวข้อสำคัญในรัฐธรรมนูญแต่ละฉบับ และทำการ Benchmark โดยวิธีการ เช่น Topic coherence, Topic Diversity
- 7. Product**
 - a.** Web application
 - b.** Hugging Face and Kaggle Dataset
 - c.** GitHub Repository