

CPE 232 Data Models

Mock Final Exam (ข้อสอบจำลองปลายภาค)

เวลาสอบ: 3 ชั่วโมง | คะแนนเต็ม: 100 คะแนน | สอบ Onsite

ประกาศและขอบเขตข้อสอบ

ข้อสอบครอบคลุมเนื้อหา Lecture 6–9 ได้แก่ Machine Learning Classification, Regression, Parameter Tuning และ Clustering ข้อสอบเน้น

ข้อเขียนและคำนวณ (ประมาณ 90%) MCQ มีเพียงเล็กน้อย

สิ่งที่อนุญาต: เครื่องเขียน, บัตรนักศึกษา และ Formula Sheet ที่อาจารย์แจกให้ (ไม่ต้องท่องสูตร)

โครงสร้างคะแนน: Part 1 (10) | Part 2 (10) | Part 3 (15) | Part 4 (30) | Part 5 (35)

Part 1: Multiple Choice / Multiple Selection / True-False (10 คะแนน)

1.1 Multiple Choice — เลือกคำตอบที่ถูกต้องที่สุด 1 ข้อ (5 ข้อ ข้อละ 1 คะแนน)

- งานใดต่อไปนี่ที่ไม่เหมาะกับ Clustering?
 - การแบ่งกลุ่มลูกค้าตามพฤติกรรมการซื้อ
 - การสรุปลักษณะประชากรในแต่ละกลุ่ม
 - การดึงข้อมูลจากฐานข้อมูลด้วยเงื่อนไขที่กำหนด
 - การหาคนที่มีความผิดปกติแตกต่างไปจากคนอื่น (Anomaly)
- การวัดประสิทธิภาพข้อใดต่อไปนี่ที่ไม่เหมาะสมกับแบบจำลอง Regression?
 - RMSE
 - R^2 Score
 - MAE
 - Precision
- แบบจำลอง Machine Learning ใดที่ใช้หลักการหาความเหมือน (Similarity) เป็นหลักในการทำนาย?
 - Logistic Regression
 - K-Nearest Neighbors (KNN)
 - Decision Tree
 - Linear Regression
- สมการ Linear Regression ในข้อใดมี Interaction Term?
 - $= c_0 + c_1x_1$
 - $= c_0 + c_1x_1 + c_2x_2$
 - $= c_0 + c_1x_1 + c_2x_2 + c_3x_1x_2$
 - $= c_0x_1 + c_1x_2$

5. ข้อใดไม่ถูกต้องเกี่ยวกับ Hierarchical Clustering?

- a. Dendrogram เป็นตัวแทนที่แสดงให้เห็นถึงความใกล้เคียงของข้อมูล
- b. ในขั้นตอนแรก ข้อมูลแต่ละตัวอย่างจะถูกถือว่าเป็นหนึ่ง Cluster
- c. เราสามารถหากลุ่ม (Cluster) ได้โดยการตัด Dendrogram ที่ระดับความสูงที่เหมาะสม
- d. ข้อมูลแต่ละตัวจะถูกกำหนดเข้าไปอยู่ใน Cluster ที่มี Centroid ใกล้ที่สุดในการอัปเดตแต่ละรอบ

1.2 Multiple Selection — เลือกทุกข้อที่ถูกต้อง (3 ข้อ ข้อละ 1 คะแนน)

หมายเหตุ: ต้องเลือกครบถ้วนทุกข้อที่ถูกต้องจึงจะได้คะแนน

6. ข้อใดบ้างเป็น Hyperparameter (กำหนดก่อน training)?

- a. `max_depth` ของ Decision Tree
- b. ค่า weight ที่ model เรียนรู้ระหว่าง Gradient Descent
- c. Learning Rate (α) ใน Gradient Descent
- d. จำนวนคลัสเตอร์ (k) ใน K-Means (`n_estimators`)
- e. ค่า bias term ที่ optimize ผ่าน loss function

7. ข้อใดบ้างช่วยลด Overfitting ได้?

- a. เพิ่มข้อมูล training
- b. ลด `max_depth` ใน Decision Tree
- c. เพิ่มจำนวน features ใน dataset
- d. ใช้ L1/L2 Regularization
- e. เพิ่ม learning rate เป็น 2 เท่า

8. ข้อใดบ้างเป็นข้อความที่ถูกต้องเกี่ยวกับ Silhouette Score?

- a. ค่าอยู่ในช่วง $[-1, +1]$
- b. ค่าใกล้ +1 บ่งชี้ว่า cluster มีความแน่นและแยกจากกันชัดเจน
- c. ค่าลบหมายความว่าจุดนั้นถูก assign ผิด cluster
- d. ค่า 0 บ่งชี้ว่า cluster สมบูรณ์แบบ
- e. ใช้ได้เฉพาะกับ K-Means เท่านั้น

1.3 True/False — ระบุ จริง (T) หรือ เท็จ (F) (4 ข้อ ข้อละ 0.5 คะแนน)

เขียน T หรือ F ในช่องว่าง

9. Entropy = 0 หมายความว่า node นั้นไม่บริสุทธิ์ (impure) อย่างสมบูรณ์

10. ค่า R^2 (Coefficient of Determination) อาจมีค่าติดลบได้ในบางกรณี
11. K-Means รับประกันว่า converge ไปที่ global optimum เสมอ
12. Stratified k-Fold Cross-Validation รักษาสัดส่วน class ในแต่ละ fold ให้ใกล้เคียงกับ dataset ต้นฉบับ

Part 2: Definition — เขียนนิยามความหมายของคำศัพท์ต่อไปนี้ (10 คะแนน, ข้อละ 1 คะแนน)

คำชี้แจง: ตอบเป็นภาษาไทยหรือภาษาอังกฤษก็ได้ ให้นิยามที่ครอบคลุมทั้งความหมายและบริบทการใช้งาน

1. Descriptive Analytics [Intro]

2. Diagnostic Analytics [Intro]

3. Predictive Analytics [Intro]

4. Prescriptive Analytics [Intro]

5. Confusion Matrix [Lecture 6]

6. Overfitting [Lecture 8]

7. Hyperparameter [Lecture 8]

8. k-Fold Cross-Validation [Lecture 8]

9. Silhouette Score

[Lecture 9]

10. DBSCAN (Density-Based Spatial Clustering)

[Lecture 9]

Part 3: Short Answer & Data Interpretation (15 คะแนน, ข้อละ 3 คะแนน)

คำชี้แจง: ตอบสั้น 2-4 บรรทัด เน้นการ “ตีความ” และ “อธิบายเหตุผล” ไม่ใช่เพียงแค่นิยาม

1. [Lecture 6] หากสร้างแบบจำลอง Decision Tree แล้วพบว่ามีปัญหา Overfitting (จำข้อมูล Training ได้เกือบหมด แต่ Test Accuracy ต่ำมาก) เราสามารถปรับ Hyperparameter ได้บ้างเพื่อแก้ปัญหานี้? (ยกตัวอย่างมา 2 พารามิเตอร์พร้อมอธิบายพอสังเขป)

2. [Lecture 8] ระบบ AI ผ่าน training ด้วย Training Accuracy = 98% แต่เมื่อทดสอบกับข้อมูลใหม่ Test Accuracy = 62% ปัญหาคืออะไร? ควรแก้ไขอย่างไรบ้าง (ระบุอย่างน้อย 2 วิธี)

3. [Lecture 6] จาก Confusion Matrix ด้านล่าง จงตีความผลลัพธ์และอธิบายว่า classifier นี้มีจุดแข็งและจุดอ่อนอะไร ควรปรับปรุงอย่างไร

	ทำนาย: บวก (+)	ทำนาย: ลบ (-)
จริง: บวก (+)	20 (TP)	80 (FN)
จริง: ลบ (-)	5 (FP)	95 (TN)

4. [Lecture 9] ในการทำ Clustering เพราะเหตุใดจึงอาจพิจารณาเลือกใช้ K-Medoids แทน K-Means? อธิบายความแตกต่างของทั้ง 2 วิธีนี้มาพอสังเขป

5. [Business Application] สมมติคุณสร้างโมเดลทำนายการซื้อขายซื้อสินค้าและพบผลลัพธ์ว่า ‘กลุ่มลูกค้าที่น่าจะซื้อสินค้าใหม่มากที่สุดคือ กลุ่มนิสิตนักศึกษา ในช่วงเวลา 20.00-24.00 น.’ ในเชิงธุรกิจ คุณจะออกนโยบายหรือกลยุทธ์ (Take action) อย่างไรเพื่อเพิ่มยอดขายหรือสร้างประสบการณ์ที่ดีให้กับลูกค้ากลุ่มนี้? (ยกตัวอย่าง 2 กลยุทธ์)

Part 4: Long Answer / Essay (30 คะแนน)

คำชี้แจง: ตอบอย่างครบถ้วน ใช้ตารางหรือเรียงความก็ได้ ประเมินจากความครบถ้วน ความถูกต้อง และความชัดเจน

ข้อ 1 — การเลือกใช้เทคนิค Machine Learning และ Algorithm (10 คะแนน)

บริษัท E-Commerce แห่งหนึ่งมีโจทย์ทางธุรกิจ 3 โจทย์ด้านล่าง:

- โจทย์ A: ทายว่าลูกค้าจะกดยกเลิกสั่งซื้อสินค้าหรือไม่ (บอกเป็น ใช่ / ไม่ใช่)
- โจทย์ B: คาดการณ์ยอดใช้จ่ายของลูกค้าแต่ละคนในเดือนหน้า (มูลค่าเป็นบาท)
- โจทย์ C: แบ่งกลุ่มลูกค้าเพื่อนำไปจัดแคมเปญโปรโมชั่นได้ตรงตามไลฟ์สไตล์

จงเลือกจับคู่โจทย์ A, B, C กับเทคนิค ML ที่เหมาะสม (Classification, Regression, Clustering) พร้อมทั้งแนะนำ Algorithm ที่เรียนมาในวิชานี้ อย่างน้อย 1 Algorithm สำหรับแต่ละโจทย์ และให้เหตุผลสนับสนุนสั้นๆ

ข้อ 2 — Types of Cross-Validation (10 คะแนน)

ส่วนที่ 2.1 อธิบาย Cross-Validation 4 แบบต่อไปนี้ โดยระบุ concept, ข้อดี, ข้อจำกัด, และเหมาะกับ dataset แบบใด:

- k-Fold Cross-Validation
- Stratified k-Fold Cross-Validation
- Leave-One-Out Cross-Validation (LOO-CV)
- Time Series Cross-Validation

ส่วนที่ 2.2 สถานการณ์ต่อไปนี้ควรใช้ Cross-Validation แบบใด พร้อมให้เหตุผล (1 คะแนน/ข้อ)

- a. Dataset ราคาหุ้น SET50 ย้อนหลัง 5 ปี ต้องการ predict ราคาวັນถัดไป

ตอบ:

- b. Dataset ตรวจมะเร็ง 200 samples (Positive 10%, Negative 90%)

ตอบ:

ข้อ 3 — การประยุกต์ใช้ 4 Types of Analytics (10 คะแนน)

สมมติว่าคุณเป็นนักวิเคราะห์ข้อมูลของร้านค้าปลีก (Retail Store) บริษัทพบว่ายอดขายสาขาในห้างตกต่ำลง 15% จงประยุกต์ใช้ 4 Types of Analytics เพื่อนำเสนอโซลูชัน:

1. **Descriptive Analytics** (2.5 คะแนน) - จะดูข้อมูลส่วนใดหรือหา Insight อะไรเพื่อดูสิ่งที่เกิดขึ้น?
2. **Diagnostic Analytics** (2.5 คะแนน) - จะตั้งสมมติฐานหรือวิเคราะห์หาสาเหตุอย่างไร?
3. **Predictive Analytics** (2.5 คะแนน) - จะสร้างโมเดลคาดการณ์เรื่องใดในอนาคตเพื่อช่วยร้านค้า?
4. **Prescriptive Analytics** (2.5 คะแนน) - จะแนะนำ Automation หรือ Policy optimization อะไรให้ระบบทำงานได้เอง?

Part 5: Calculation Structure (35 คะแนน)

คำชี้แจง: แสดงวิธีทำให้ครบทุกขั้นตอน คำตอบที่ไม่มีวิธีทำจะไม่ได้คะแนน

ข้อ 5.1 — Confusion Matrix Metrics (10 คะแนน)

ระบบ AI วินิจฉัยโรคเบาหวาน ทดสอบกับ 200 patients ได้ผลดังนี้:

	ทำนาย: ป่วย (+)	ทำนาย: ไม่ป่วย (-)	รวม
จริง: ป่วย (+)	60	20	80
จริง: ไม่ป่วย (-)	40	80	120
รวม	100	100	200

5.1.1 (5 คะแนน) คำนวณค่าต่อไปนี้พร้อมแสดงวิธีคิด:

- Accuracy
- Precision
- Recall (Sensitivity)
- Specificity
- F1-Score

5.1.2 (5 คะแนน) จากผลลัพธ์ข้างต้น จงตีความ: ระบบนี้เหมาะสมสำหรับการวินิจฉัยโรคหรือไม่? metric ใดสำคัญที่สุดในบริบทนี้? และควรปรับปรุงอย่างไร?

ข้อ 5.2 — Regression: MSE, RMSE, MAE และ R^2 (10 คะแนน)

จาก dataset ต่อไปนี้ model Linear Regression ให้ค่า predict ดังนี้:

#	y_{actual}	$y_{\text{predicted}}$
1	2	2
2	4	4
3	5	6
4	8	8
5	11	10

5.2.1 (10 คะแนน) คำนวณค่าต่อไปนี้พร้อมแสดงวิธีคิดทุกขั้น:

- MSE (Mean Squared Error)
- RMSE (Root MSE)
- MAE (Mean Absolute Error)
- SSE และ SS_{total}
- R^2 (Coefficient of Determination)

ข้อ 5.3 — Hierarchical Agglomerative Clustering + Dendrogram + Nested Clusters (15 คะแนน)

ใช้ Complete Linkage: $d(\{C_i\}, \{C_j\}) = \max_{x \in C_i, y \in C_j} d(x, y)$

กำหนด Proximity Matrix ของจุดข้อมูล 5 จุด (A, B, C, D, E):

	A	B	C	D	E
A	0	1	5	6	7
B	1	0	4	6	8
C	5	4	0	2	3
D	6	6	2	0	3
E	7	8	3	3	0

5.3.1 (6 คะแนน) แสดงขั้นตอน Agglomerative Clustering ทีละ step จนเหลือ 1 cluster:

ระบุ: (1) คู่ที่ merge, (2) ระยะทางที่ merge, (3) Proximity Matrix ที่อัปเดตแล้ว ทุก iteration

5.3.2 (5 คะแนน) วาด Dendrogram โดยระบุแกน Y เป็นระยะทาง (distance) และแสดงระดับที่ merge แต่ละครั้งให้ชัดเจน

5.3.3 (2 คะแนน) วาด Nested Cluster Diagram แสดงการ group จุดข้อมูลในแต่ละ level

5.3.4 (2 คะแนน) ถัดตัด Dendrogram ที่ระดับ $d = 4$ จะได้กี่ cluster และประกอบด้วยจุดใดบ้าง?

เฉลยและแนวคิด (Answer Key)

ส่วนนี้สำหรับตรวจหลังทำข้อสอบ แนะนำให้ทำข้อสอบเต็มเวลาก่อนเปิดเฉลย

Part 1: คำตอบ

1.1 MCQ

1. c. 2. d. 3. b. 4. c. 5. d.

1.2 Multiple Selection

- ข้อ 6: a, c, d (max_depth, Learning Rate, n_estimators คือ Hyperparameters; b,e คือ learned parameters)
- ข้อ 7: a, b, d (เพิ่มข้อมูล, ลด max_depth, L1/L2 Reg ลด overfit; c เพิ่ม features อาจทำ overfit มากขึ้น; e เพิ่ม LR อาจทำให้ diverge)
- ข้อ 8: a, b, c (ช่วง -1 ถึง +1, ค่าใกล้ +1 ดี, ค่าลบ = misclustered; d ผิด ค่า 0 = on boundary; e ผิด Silhouette ใช้กับ clustering ทั่วไป)

1.3 True/False

9. F (Entropy=0 คือ 10. T ($R^2 < 0$ ได้) 11. F (แค่ local optima) 12. T (Stratified รักษา class ratio)

Part 2: แนวคำตอบ (Definitions)

1. **Entropy:** วัดความไม่แน่นอน (impurity) ของ node ใน Decision Tree $H(S) = - \sum_i p_i \log_2 p_i$ ค่า 0 = pure (class เดียว), ค่า 1 = equally mixed สองคลาส
2. **Information Gain:** การลดลงของ Entropy หลังแบ่งข้อมูลด้วย attribute นั้น $IG(S, A) = H(S) - \sum_v \frac{|S_v|}{|S|} H(S_v)$ ยิ่งสูงยิ่งเป็น attribute ที่ดีสำหรับ split
3. **Confusion Matrix:** ตาราง 2x2 (หรือ nxn) แสดงผล classification ประกอบด้วย TP (ทำนายถูก-บวก), TN (ทำนายถูก-ลบ), FP (ทำนายผิด-positive), FN (ทำนายผิด-negative)
4. **Overfitting:** สภาวะที่ model เรียนรู้ noise ใน training data จน Training acc สูงมาก แต่ Test acc ต่ำ — model ไม่สามารถ generalize กับข้อมูลใหม่ได้
5. **Gradient Descent:** Algorithm ปรับ parameter โดย update ในทิศทางตรงข้าม gradient ของ loss $\theta := \theta - \alpha \cdot \nabla_{\theta} L(\theta)$ เพื่อลด loss function ที่ละขั้น
6. **Hyperparameter:** Parameter ที่กำหนดก่อน training และไม่ถูก optimize โดย model เช่น max_depth, learning_rate, k ใน KNN ต่างจาก learnable parameters ที่ model เรียนรู้ระหว่าง training
7. **k-Fold CV:** แบ่ง dataset เป็น k ส่วนเท่า ๆ กัน วนซ้ำ k รอบ โดยแต่ละรอบใช้ส่วนต่างกันเป็น validation set ที่เหลือเป็น training ค่า metric เฉลี่ยจาก k รอบ = ประสิทธิภาพของ model
8. **Centroid:** จุดศูนย์กลางของ cluster ใน K-Means คำนวณจากค่าเฉลี่ยของ feature ทุกมิติของจุดทั้งหมดใน cluster $\mu_k = \frac{1}{|C_k|} \sum_{x \in C_k} x$

9. **Silhouette Score:** วัดคุณภาพ clustering ช่วง $[-1, +1]$ โดย $s(i) = \frac{b(i)-a(i)}{\max(a(i), b(i))}$ โดย a =ระยะเฉลี่ยใน cluster, b =ระยะเฉลี่ยไปยัง cluster ใกล้ที่สุด ค่าสูงหมายถึง cluster ดี
10. **DBSCAN:** Algorithm clustering แบบ density-based กำหนด core points ด้วย ϵ (รัศมี) และ MinPts (จำนวนจุดขั้นต่ำ) ไม่ต้องระบุ k ล่วงหน้า จัดการ noise ได้ และ cluster มีรูปร่างได้อิสระ

Part 3: แนวคำตอบ

1. **Decision Tree Hyperparameters:** เพื่อลด Overfitting สามารถปรับพารามิเตอร์เช่น (1) ลด max_depth (จำกัดความลึกของต้นไม้ไม่ให้แตกกิ่งลึกเกินไป) หรือ (2) เพิ่ม min_samples_split/leaf (กำหนดจำนวน sample ขั้นต่ำในการแตกกิ่ง เพื่อไม่ให้โมเดลสร้างกิ่งสำหรับข้อมูลที่น้อยและเฉพาะเจาะจงเกินไป)
2. **Overfitting:** Training 98%, Test 62% คือ Overfitting ชัดเจน Model จดจำ training data มากเกินไป วิธีแก้: (1) ลด max_depth / เพิ่ม min_samples_split ใน DT (2) เพิ่ม L1/L2 Regularization (3) ใช้ k-Fold CV เพื่อ estimate performance จริง (4) เพิ่มข้อมูล training (5) Early Stopping
3. **CM Interpretation:** TP=20, FN=80 หมายความว่า Recall = $20/100 = 0.20$ ต่ำมาก — model “พลาด” ผู้ป่วยจริง 80% ถือว่าอันตรายมาก ในบริบทการแพทย์ ควรปรับ decision threshold ให้ต่ำลง เพื่อให้ model ตรวจจับ positive case ได้ดีขึ้น
4. **Silhouette 0.12:** ค่า 0.12 ใกล้ 0 บ่งชี้ว่า cluster ทับซ้อนกัน หรือจุดข้อมูลอยู่บน boundary ระหว่าง cluster — คุณภาพการ cluster ต่ำมาก วิธี diagnose: ใช้ Elbow Method (plot WCSS vs k) หรือ Silhouette Score vs k เพื่อหาค่า k ที่เหมาะสม
5. **Local Minimum:** เกิดเมื่อ gradient ลด loss ลงมาจนติดอยู่ที่จุดต่ำสุดเฉพาะที่ที่ไม่ใช่ global minimum gradient = 0 แต่ไม่ใช่คำตอบที่ดีที่สุด Adam optimizer แก้ปัญหาด้วยการรวม Momentum (สะสม gradient) และ Adaptive Learning Rate (ปรับ LR ตาม parameter) ทำให้ออกจาก local minimum และ saddle point ได้ดีกว่า SGD ธรรมดา

Part 4: แนวคำตอบ

ข้อ 1: การเลือกใช้เทคนิค Machine Learning

โจทย์ A (Churn/Cancel Prediction):

- **เทคนิค:** Classification (เพราะผลลัพธ์เป็นหมวดหมู่ ใช่/ไม่ใช่)
- **Algorithm ยอมรับคำตอบเช่น:** Decision Tree, Logistic Regression, หรือ KNN (ตอบมา 1 อย่าง) โดยให้เหตุผลเช่น Decision Tree สามารถอธิบายเหตุผลด้วยกฎได้ชัดเจน

โจทย์ B (Spending Prediction):

- **เทคนิค:** Regression (เพราะผลลัพธ์เป็นตัวเลขต่อเนื่อง หรือมูลค่าทางการเงิน)
- **Algorithm ยอมรับคำตอบเช่น:** Linear Regression เป็นต้น โดยให้เหตุผลว่าสามารถหาความสัมพันธ์และน้ำหนักระหว่างตัวแปรกับยอดขายได้

โจทย์ C (Customer Segmentation):

- **เทคนิค:** Clustering / Unsupervised Learning (เพราะเป็นการแบ่งกลุ่มโดยไม่มีผลเฉลยล่วงหน้า)
- **Algorithm ยอมรับคำตอบเช่น:** K-Means, K-Medoids, DBSCAN, หรือ Hierarchical Clustering โดยให้เหตุผลเช่น K-Means เหมาะกับการจัดกลุ่มให้มีจำนวนกลุ่มตามที่กำหนดไว้ได้รวดเร็ว

ข้อ 2: Cross-Validation Types

ประเภท	Concept	ข้อดี / ข้อจำกัด	เหมาะกับ
k-Fold	แบ่ง k ส่วน วน k รอบ	ประเมิน variance ดี / ใช้เวลา k เท่า	Dataset ทั่วไป balanced
Stratified k-Fold	k-Fold แต่รักษา class ratio ทุก fold	ดีกับ imbalanced / ใช้เวลาเท่า k-Fold	Class imbalanced
LOO-CV	$k = n$, test ทีละ 1 sample	ใช้ข้อมูลได้สูงสุด / ช้ามาก $O(n)$	Dataset เล็ก ($n < 100$)
Time Series CV	ขยาย training window ทีละ step	ไม่ data leakage จากอนาคต / ต้องเรียง	Time series, sequential data

ส่วน 2.2: (a) Stock price → **Time Series CV** เพราะข้อมูลมี temporal dependency ห้ามสุ่ม

(b) Cancer dataset imbalanced → **Stratified k-Fold** เพื่อรักษา class ratio ใน fold

Part 5: เอลยการคำนวณ

5.1 Entropy & Information Gain

Dataset: 8 samples, 4 ใช่ (+), 4 ไม่ใช่ (-) $\Rightarrow H(S) = -\frac{4}{8} \log_2 \frac{4}{8} - \frac{4}{8} \log_2 \frac{4}{8} = -\frac{1}{2}(-1) - \frac{1}{2}(-1) = 1.0$ bit

รายได้ (Income):

- สูง (High): rows 1,2,3 $\rightarrow$ 3 ใช่, 0 ไม่ใช่ $\Rightarrow H = 0$
- ปานกลาง (Medium): rows 4,5 $\rightarrow$ 1 ใช่, 1 ไม่ใช่ $\Rightarrow H = 1.0$
- ต่ำ (Low): rows 6,7,8 $\rightarrow$ 0 ใช่, 3 ไม่ใช่ $\Rightarrow H = 0$
- $IG(\text{Income}) = 1.0 - \frac{3}{8}(0) - \frac{2}{8}(1.0) - \frac{3}{8}(0) = 1.0 - 0.25 = 0.75$

นักศึกษา (Student):

- ใช่: rows 1,2,4,7 $\rightarrow$ 3 ใช่, 1 ไม่ใช่ $\Rightarrow H = -\frac{3}{4} \log_2 \frac{3}{4} - \frac{1}{4} \log_2 \frac{1}{4} = -\frac{3}{4}(1.585 - 2) - \frac{1}{4}(-2) = \frac{3}{4}(0.415) + 0.5 \approx 0.811$
- ไม่ใช่: rows 3,5,6,8 $\rightarrow$ 1 ใช่, 3 ไม่ใช่ $\Rightarrow H = 0.811$ (symmetric)
- $IG(\text{Student}) = 1.0 - \frac{4}{8}(0.811) - \frac{4}{8}(0.811) = 1.0 - 0.811 = 0.189$

อายุ (Age):

- น้อยกว่า 30: rows 1,2,5,6 $\rightarrow$ 2 ใช่, 2 ไม่ใช่ $\Rightarrow H = 1.0$
- 30-50: rows 3,4,7,8 $\rightarrow$ 2 ใช่, 2 ไม่ใช่ $\Rightarrow H = 1.0$
- $IG(\text{Age}) = 1.0 - \frac{4}{8}(1.0) - \frac{4}{8}(1.0) = 0.0$

สรุป IG: Income = 0.75 > Student = 0.189 > Age = 0.0

Root Node = รายได้ (Income) เพราะให้ Information Gain สูงสุด

5.2 Confusion Matrix

TP=60, FP=40, FN=20, TN=80, Total=200

$$\text{Accuracy} = \frac{60 + 80}{200} = \frac{140}{200} = 0.70$$

$$\text{Precision} = \frac{60}{60 + 40} = \frac{60}{100} = 0.60$$

$$\text{Recall} = \frac{60}{60 + 20} = \frac{60}{80} = 0.75$$

$$\text{Specificity} = \frac{80}{80 + 40} = \frac{80}{120} \approx 0.667$$

$$F1 = \frac{2 \times 0.60 \times 0.75}{0.60 + 0.75} = \frac{0.90}{1.35} = \frac{2}{3} \approx 0.667$$

ตีความ: Recall = 0.75 หมายถึงผู้ป่วยจริง 25% ถูกพลาด (FN=20) ในบริบทการแพทย์ FN อันตรายกว่า FP เพราะผู้ป่วยไม่ได้รับการรักษา
ควรลด threshold เพื่อเพิ่ม Recall แม้ Precision จะลดลงบ้าง

5.3 Regression

errors ($e_i = y_{actual} - y_{pred}$): 0, 0, -1, 0, 1

$$MSE = \frac{0^2 + 0^2 + (-1)^2 + 0^2 + 1^2}{5} = \frac{2}{5} = 0.40, \quad RMSE = \sqrt{0.40} \approx 0.632$$

$$MAE = \frac{0 + 0 + 1 + 0 + 1}{5} = 0.40$$

$$\bar{y} = \frac{2 + 4 + 5 + 8 + 11}{5} = 6.0 \quad SSE = \sum (y_i - \hat{y}_i)^2 = 0 + 0 + 1 + 0 + 1 = 2$$

$$SS_{total} = (2 - 6)^2 + (4 - 6)^2 + (5 - 6)^2 + (8 - 6)^2 + (11 - 6)^2 = 16 + 4 + 1 + 4 + 25 = 50$$

$$R^2 = 1 - \frac{SSE}{SS_{total}} = 1 - \frac{2}{50} = 0.96$$

$$\text{Gradient Descent: } \theta_0^{new} = 1.0 - 0.1 \times 2.0 = 0.80, \quad \theta_1^{new} = 0.5 - 0.1 \times (-1.5) = 0.5 + 0.15 = 0.65$$

5.4 K-Means

Iteration 1 ($\mu_1 = (1, 1)$, $\mu_2 = (8, 4)$):

จุด	$d(\cdot, \mu_1)$	$d(\cdot, \mu_2)$	Cluster
A(1,1)	0	$\sqrt{58} \approx 7.62$	1
B(2,3)	$\sqrt{5} \approx 2.24$	$\sqrt{37} \approx 6.08$	1
C(3,2)	$\sqrt{5} \approx 2.24$	$\sqrt{29} \approx 5.39$	1
D(6,5)	$\sqrt{41} \approx 6.40$	$\sqrt{5} \approx 2.24$	2
E(7,6)	$\sqrt{61} \approx 7.81$	$\sqrt{5} \approx 2.24$	2
F(8,4)	$\sqrt{58} \approx 7.62$	0	2

$$\mu_1^{new} = \left(\frac{1+2+3}{3}, \frac{1+3+2}{3}\right) = (2, 2), \quad \mu_2^{new} = \left(\frac{6+7+8}{3}, \frac{5+6+4}{3}\right) = (7, 5)$$

Iteration 2 ($\mu_1 = (2, 2)$, $\mu_2 = (7, 5)$): ทุกจุดยังอยู่ใน cluster เดิม (A,B,C $\rightarrow$ Cluster 1; D,E,F $\rightarrow$ Cluster 2)

Centroids ไม่เปลี่ยน $\Rightarrow$ **Converged!** ที่ Cluster 1 = {A,B,C}, Cluster 2 = {D,E,F}

5.5 Hierarchical Agglomerative Clustering

Step 1: $\min = d(A, B) = 1 \rightarrow$ Merge {A,B}

Complete Linkage: $d(\{AB\}, C) = \max(5, 4) = 5$, $d(\{AB\}, D) = \max(6, 6) = 6$, $d(\{AB\}, E) = \max(7, 8) = 8$

	{AB}	C	D	E
{AB}	0	5	6	8
C	5	0	2	3
D	6	2	0	3
E	8	3	3	0

Step 2: $\min = d(C, D) = 2 \rightarrow$ Merge {C,D}

$$d(\{AB\}, \{CD\}) = \max(5, 6) = 6, \quad d(\{CD\}, E) = \max(3, 3) = 3$$


	{AB}	{CD}	E
{AB}	0	6	8
{CD}	6	0	3
E	8	3	0

Step 3: $\min = d(\{CD\}, E) = 3 \rightarrow \text{Merge } \{C,D,E\}$


$$d(\{AB\}, \{CDE\}) = \max(6, 8) = 8$$

Step 4: Merge {AB} + {CDE} ที่ $d = 8$

Dendrogram (เฉลี่ย):



Nested Cluster Diagram (เฉลี่ย):



5.5.4: ตัดที่ $d = 4$ จะได้ 2 clusters: {A,B} และ {C,D,E}

(เพราะ {A,B} merge กันที่ $d = 1 < 4$ และ {C,D,E} merge กันที่ $d = 3 < 4$ แต่ merge กัน 2 กลุ่มใหญ่ที่ $d = 8 > 4$)

Formula Sheet (สูตรสำหรับใช้ในห้องสอบ)

อาจารย์จะแจก Formula Sheet แผ่นนี้ในห้องสอบ — ไม่ต้องท่องสูตร แต่ต้องเข้าใจวิธีใช้

Lecture 6: Classification

$$\begin{aligned} H(S) &= - \sum_{i=1}^c p_i \log_2 p_i \\ IG(S, A) &= H(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v) \\ \text{Gini}(S) &= 1 - \sum_{i=1}^c p_i^2 \\ \text{Sigmoid}(z) &= \frac{1}{1 + e^{-z}} \end{aligned}$$
$$\begin{aligned} \text{Accuracy} &= \frac{TP + TN}{TP + TN + FP + FN} \\ \text{Precision} &= \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN} \\ \text{F1} &= \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \\ \text{Specificity} &= \frac{TN}{TN + FP} \end{aligned}$$

Lecture 7: Regression

$$\begin{aligned} \text{MSE} &= \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ \text{RMSE} &= \sqrt{\text{MSE}}, \quad \text{MAE} = \frac{1}{n} \sum |y_i - \hat{y}_i| \\ R^2 &= 1 - \frac{SSE}{SS_{total}} = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} \end{aligned}$$
$$\begin{aligned} \theta_j &:= \theta_j - \alpha \cdot \frac{\partial L}{\partial \theta_j} \\ L_{\text{Ridge}} &= L + \lambda \sum \theta_j^2 \\ L_{\text{Lasso}} &= L + \lambda \sum |\theta_j| \end{aligned}$$

Lecture 9: Clustering

$$\begin{aligned} d_{\text{Euclidean}} &= \sqrt{\sum_k (x_k - y_k)^2} \\ d_{\text{Manhattan}} &= \sum_k |x_k - y_k| \\ \text{WCSS} &= \sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2 \end{aligned}$$
$$\begin{aligned} s(i) &= \frac{b(i) - a(i)}{\max(a(i), b(i))} \\ d_{\text{Complete}}(C_i, C_j) &= \max_{x \in C_i, y \in C_j} d(x, y) \\ d_{\text{Single}}(C_i, C_j) &= \min_{x \in C_i, y \in C_j} d(x, y) \end{aligned}$$

RECAP: สรุปเนื้อหาจำสอบ (อ่านก่อนสอบ)

RECAP 1: Classification (Lecture 6)

- **Decision Tree:** เลือก root ด้วย IG สูงสุด, Entropy=0 คือ pure node, Gini ใช้แทน Entropy ได้
- **KNN:** หา k เพื่อนบ้านใกล้สุด, ขั้นตอน predict, ไม่มี training phase, ต้อง scale features
- **Confusion Matrix จำ:** TP=ทำนายถูก-บวก, FP=ทำนายผิด-บวก (False Alarm), FN=พลาด positive (Missed)
- ในทางการแพทย์ FN อันตรายกว่า FP $\Rightarrow$ เน้น Recall; ในการกรอง spam เน้น Precision

RECAP 2: Regression (Lecture 7)

- **MSE** ลงโทษ outlier มากกว่า **MAE** เพราะยกกำลังสอง; **RMSE** หน่วยเดียวกับ y
- $R^2 = 1$ = perfect fit; $R^2 = 0$ = ไม่ดีกว่าการใช้ค่าเฉลี่ย; $R^2 < 0$ = แย่กว่า
- **Gradient Descent:** $\theta := \theta - \alpha \cdot \nabla L$ อัปเดต parameter ลดทาง gradient
- **Batch GD:** ใช้ทุก sample/step (stable แต่ช้า) vs **SGD:** 1 sample/step (เร็วแต่ noisy) vs **Mini-batch:** กลาง ๆ
- **Ridge (L2):** ลด magnitude weights, **Lasso (L1):** ทำให้บาง weight = 0 (feature selection)

RECAP 3: Parameter Tuning (Lecture 8)

- **Hyperparameter vs Learnable:** max_depth, LR = Hyperparameter (กำหนดก่อน); weights, bias = Learnable (model เรียนรู้)
- **Overfitting:** Train high, Test low $\Rightarrow$ แก้อย่างไร: regularization, ลด complexity, เพิ่มข้อมูล, k-Fold CV
- **k-Fold:** ทั่วไป; **Stratified k-Fold:** imbalanced class; **LOO-CV:** dataset เล็ก; **Time Series CV:** sequential
- **Grid Search:** ลอง combination ทั้งหมด (exhaustive แต่ช้า); **Random Search:** สุ่ม (เร็วกว่า); **Bayesian:** ใช้ prior ชี้นำ
- **Adam:** รวม Momentum + Adaptive LR ใช้ได้ดีกับส่วนใหญ่ ออกจาก local minimum ได้ดี
- **Learning Rate Scheduling:** ลด LR ตามเวลา (decay) ช่วย converge ได้ละเอียดขึ้น

RECAP 4: Clustering (Lecture 9)

- **K-Means:** (1) init centroids, (2) assign points, (3) update centroids, (4) repeat จน converge WCSS วัดความแน่น
- **Elbow Method:** plot WCSS vs k หา “ข้อศอก” ที่ WCSS ลดช้าลงกะทันหัน
- **Silhouette:** $[-1, +1]$; $s \approx 1$ = ดี; $s \approx 0$ = on boundary; $s < 0$ = misclustered
- **Hierarchical Agglomerative:** Bottom-up, Single/Complete/Average Linkage, ผล = Dendrogram ตัด Dendrogram ที่ระดับต่าง ๆ ได้จำนวน cluster ต่าง ๆ
- **Complete Linkage = MAX distance** ระหว่างคู่จุดของ 2 clusters; Single = MIN

- DBSCAN: ไม่ต้องกำหนด k , จัดการ noise ได้, cluster ไม่เป็น convex ได้ ϵ = รัศมี, MinPts = จุดขั้นต่ำ
- K-Means ดีเมื่อ: cluster กลม ๆ, รู้จำนวน k ; DBSCAN ดีเมื่อ: cluster รูปร่างซับซ้อน, มี noise/outlier