



คุณกำลังพิจารณาแยกชุดข้อมูลเดียวกัน โดยใช้แอตทริบิวต์ที่แบ่งชุดข้อมูลออกเป็นสองกลุ่ม: กลุ่ม A มี 25 ตัวอย่าง (20 Positive, 5 Negative) และกลุ่ม B มี 15 ตัวอย่าง (10 Positive, 5 Negative) หากค่า entropy ของชุดข้อมูลเดิม (ก่อนการแบ่ง) คือ 0.88 คำนวณ Information Gain จากการแยกโดยใช้แอตทริบิวต์นี้

A. 0.50

B. 0.20

C. 0.10

D. 0.05

Question 8 of 40

ข้อใดต่อไปนี้เป็นข้อจำกัดของ linear regression ในการใช้งานเพื่อการทำนาย

- A. ไม่สามารถเรียนรู้ Interaction ได้
- B. สามารถเรียนรู้ได้เฉพาะความสัมพันธ์เชิงเส้น
- C. หากมีตัวแปรที่สัมพันธ์กันเอง (Collinearity) ประสิทธิภาพของแบบจำลองจะลดลง
- D. ตัวแปร y จำต้องกระจายตัวแบบปกติ



หลังจากการรวบรวมข้อมูลจำนวนมากเกี่ยวกับลูกค้า บริษัทต้องการแบ่งกลุ่มลูกค้าตามความชอบและพฤติกรรมการซื้อเพื่อใช้ในการทำการตลาดแบบเจาะจง วิธีการ ML ไດที่เหมาะสมที่สุดสำหรับการจัดการปัญหานี้

A. Data visualization

B. Regression

C. Clustering

D. Classification



ในการทำโครงการด้านวิทยาศาสตร์ข้อมูลเพื่อสร้างแบบจำลอง ML ขั้นตอนใดเป็นขั้นแรกที่ต้องทำในการศึกษา

- A. การทดสอบแบบจำลอง
- B. การทำความเข้าใจข้อมูล
- C. การสร้างแบบจำลอง
- D. การทำความเข้าใจปัญหา



งานใดบ้างต่อไปนี้ที่ไม่เกี่ยวข้องกับการหาความเหมือนของข้อมูล

- A. จับกลุ่มลูกค้าที่มีพฤติกรรมเหมือนกัน
- B. การหาว่าลูกค้าคนใดมีข้อมูลที่อยู่คล้ายกัน
- C. การคำนวณคะแนนความชอบ โดยดูจากคนใกล้เคียง
- D. การหา Histogram ของข้อมูล

Question 16 of 40

งานใดต่อไปนี่ที่ไม่เหมาะกับ Clustering

- A. การหาว่าความเข้าใจเกี่ยวกับลูกค้าที่เคยมีนั้นถูกต้องหรือไม่
- B. การสรุปลักษณะของลูกค้าในแต่ละกลุ่ม
- C. การดึงข้อมูลจากฐานข้อมูลด้วยรายละเอียดที่กำหนด
- D. การหาคนที่แตกต่างไปจากคนอื่น

Question 13 of 40

การวัดความแตกต่างวิธีใดที่เหมาะสมกับข้อมูลแบบ set

- A. Jaccard
- B. Euclidean
- C. Manhattan
- D. Cosine

Question 14 of 40

ข้อใดไม่ถูกต้องเกี่ยวกับ hierarchical clustering?

- A. เราหา cluster ได้โดยการตัด dendrogram
- B. ข้อมูลแต่ละตัวจะถูกกำหนดให้กับ cluster ที่ใกล้ที่สุด
- C. ในขั้นตอนแรกของการหา dendrogram แต่ละตัวอย่างจะถูกถือว่าเป็น cluster
- D. Dendrogram เป็นตัวแทนของความใกล้กันของข้อมูล

Question 15 of 40

จากการวิเคราะห์ correlation เราได้ค่า Correlation ระหว่าง ตัวแปร A/B/C/D/E/F และตัวแปรผลลัพธ์ y ดังตาราง หากตัวแปรทุกตัวเป็นอิสระต่อกัน เราควรเลือกตัวแปรใดบ้างมาสร้างแบบจำลอง linear regression

y	A	B	C	D
1	0.1	-0.9	0.2	0.0

A. C

B. A

C. B

D. D



ให้ x_1 , x_2 แทนตัวแปรที่จะใช้ทำนายและ y แทนตัวแปรผลลัพธ์ สมการ linear regression ในข้อใดที่มี interaction term.

A. $y = c_0$

B. $y = c_0 + c_1x_1$

C. $y = c_0 + c_1x_1 + c_2x_2$

D. $y = c_0 + c_1x_1 + c_2x_2 + c_3x_1x_2$

Question 3 of 40

แบบจำลองใดที่ใช้หลักการหาความเหมือน

A. Logistic Regression

B. KNN

C. Decision Tree

D. Linear Discriminant

Question 12 of 40

ในแบบจำลอง simple linear regression ส่วนใดบ้างของแบบจำลองที่เกี่ยวข้องกับ error โดยตรง

- A. intercept.
- B. All are correct.
- C. slope.
- D. residual.



ข้อใดไม่ได้เป็นเหตุผลที่ residual ของแบบจำลอง simple linear regression จะต้องกระจายตัวแบบ $N(0, \sigma^2)$

- A. ข้อผิดพลาด (error) ถูกลดค่าลงให้ได้มากที่สุดเท่าที่จะทำได้
- B. จุดกระจายอยู่ข้างบนและข้างล่างของเส้นด้วยระยะห่างรวมพอๆ กัน
- C. ไม่มีความผิดปกติของรูปแบบการกระจายตัว
- D. เส้นผ่านการข้อมูลเป็นแนวโน้ม (trend)



งานใดต่อไปนี่ที่ไม่เหมาะกับ Clustering

- A. การหาว่าความเข้าใจเกี่ยวกับลูกค้าที่เคยมีนั้นถูกต้องหรือไม่
- B. การสรุปลักษณะของลูกค้าในแต่ละกลุ่ม
- C. การหาคนที่แตกต่างไปจากคนอื่น
- D. การดึงข้อมูลจากฐานข้อมูลด้วยรายละเอียดที่กำหนด



คุณกำลังสร้าง Decision Tree โมเดล (tree_model) เพื่อทำนายว่าลูกค้าจะซื้อผลิตภัณฑ์ใหม่หรือไม่ จากฐานข้อมูลของลูกค้า คุณต้องการทราบว่าฟีเจอร์ใดมีผลต่อการตัดสินใจมากที่สุด คำสั่งไหนต่อไปนี้จะช่วยให้คุณสามารถดูความสำคัญของแต่ละฟีเจอร์ในการตัดสินใจของโมเดล

- A. tree_model.fit()
- B. tree_model.decision_path()
- C. tree_model.predict_proba()
- D. tree_model.feature_importances_

การวัดประสิทธิภาพข้อใดต่อไปนี่ที่ไม่เหมาะสมกับแบบจำลอง regression

A. RMSE

B. R^2

C. MAE

D. Precision

Question 19 of 40

งานในข้อใดที่เหมาะสมกับการใช้แบบจำลอง Classification

- A. การลดรูปข้อมูล
- B. การแบ่งกลุ่มลูกค้า
- C. การทำเหมือง Association Rule
- D. การทำนายโอกาสการไม่ชำระเงินของลูกค้า

ในการทดลองกับข้อมูลการทำนายการเกิดโรคในผู้ป่วย, คุณพบว่าโมเดล Decision Tree ของคุณมีความแม่นยำ (accuracy) ที่สูงแต่มีค่า recall ที่ต่ำมากสำหรับคลาสที่สำคัญ การปรับค่าพารามิเตอร์ใดต่อไปนี้อาจช่วยเพิ่มค่า recall ได้

A. ลดค่า min_samples_split

B. เพิ่มค่า min_samples_leaf

C. เพิ่มค่า max_depth

D. ลดค่า max_leaf_nodes